

a) Faça um boxplot analisando a média e desvio padrão dos valores de cada feature e se há outliers.

```

----- MÉDIA -----
alcohol                13.000618
malic_acid             2.336348
ash                   2.366517
alcalinity_of_ash      19.494944
magnesium             99.741573
total_phenols          2.295112
flavanoids            2.029270
nonflavanoid_phenols   0.361854
proanthocyanins        1.590899
color_intensity        5.058090
hue                   0.957449
od280/od315_of_diluted_wines 2.611685
proline               746.893258
target                0.938202
Name: mean, dtype: float64


----- DESVIO PADRÃO -----
alcohol                0.811827
malic_acid             1.117146
ash                   0.274344
alcalinity_of_ash      3.339564
magnesium             14.282484
total_phenols          0.625851
flavanoids            0.998859
nonflavanoid_phenols   0.124453
proanthocyanins        0.572359
color_intensity        2.318286
hue                   0.228572
od280/od315_of_diluted_wines 0.709990
proline               314.907474
target                0.775035
Name: std, dtype: float64

```


Ao analisar o dataset Wine, é possível observar que as features apresentam escalas bastante diferentes entre si. Algumas variáveis possuem valores pequenos, enquanto outras possuem amplitudes muito maiores, como o atributo **proline**, que apresenta valores significativamente superiores aos demais. Isso faz com que o boxplot original fique visualmente desbalanceado.

A análise das médias e desvios padrão mostra que os atributos possuem distribuições distintas. Features como **alcohol**, **malic_acid** e **ash** possuem desvios padrão menores, indicando menor dispersão dos dados em relação à média. Já atributos como **proline**, **magnesium** e **color_intensity** apresentam desvios padrão elevados, indicando maior variabilidade entre as amostras.

Também foi possível identificar a presença de outliers em algumas features. Os outliers aparecem como pontos fora dos limites do boxplot e representam valores muito distantes da distribuição principal dos dados. As variáveis que mais apresentaram outliers foram: **magnesium**, **proline**, **color_intensity** e **malic_acid**.




b) Aplique um método de normalização dos dados e gere novamente o boxplot.



Após aplicar a normalização utilizando o método StandardScaler, os dados passaram a possuir média próxima de zero e desvio padrão próximo de um. Isso faz com que todas as variáveis fiquem na mesma escala, permitindo comparações mais equilibradas entre as features.

No novo boxplot, observa-se que as distribuições ficaram muito mais homogêneas. As caixas passaram a possuir tamanhos semelhantes e os valores extremos ficaram menos desproporcionais visualmente. Apesar disso, os outliers continuam existindo, pois a normalização não remove valores extremos, apenas ajusta a escala dos dados.

c) Plote um gráfico com a distribuição de elementos em cada classe.




O gráfico de distribuição das classes mostra que o dataset Wine possui três classes diferentes de vinhos. As classes estão relativamente balanceadas, embora não possuam exatamente a mesma quantidade de elementos. A distribuição observada é aproximadamente:

- Classe 0: maior quantidade de amostras
- Classe 1: quantidade intermediária
- Classe 2: menor quantidade

Mesmo existindo pequenas diferenças, o conjunto de dados não apresenta um grande desbalanceamento. Isso é positivo para

tarefas de classificação, pois reduz a chance de o modelo favorecer excessivamente uma classe específica.

d) Plote a matriz de correlação entre as features e indique quais atributos tem maior correlação entre si.



A matriz de correlação permite identificar relações lineares entre as variáveis do dataset. Correlações próximas de 1 indicam forte relação positiva, enquanto valores próximos de -1 indicam forte relação negativa. Foi possível observar algumas correlações fortes entre atributos químicos do vinho. As principais correlações positivas encontradas foram:


- **total_phenols** e **flavanoids**
- **flavanoids** e **od280/od315_of_diluted_wines**

Isso indica que, quando uma dessas variáveis aumenta, a outra tende a aumentar também. Também foram observadas correlações negativas, principalmente entre:

- **color_intensity** e **hue**

Nesse caso, quando a intensidade da cor aumenta, o valor de **hue** tende a diminuir.

e) Plote um gráfico 2D aplicando PCA.



O PCA (Principal Component Analysis) foi utilizado para reduzir as 13 dimensões originais do dataset para apenas duas componentes principais. Essas componentes representam combinações lineares das features originais e concentram a maior parte da variância dos dados.

No gráfico 2D gerado pelo PCA, foi possível observar uma separação relativamente clara entre as três classes do dataset. A classe 0 aparece mais isolada, enquanto as classes 1 e 2 apresentam uma pequena sobreposição em algumas regiões.

Essa separação indica que os atributos químicos do vinho possuem informações suficientes para diferenciar os tipos de vinho mesmo após a redução de dimensionalidade.

Além disso, o PCA facilita a visualização dos dados e permite identificar padrões e agrupamentos que seriam difíceis de perceber em um espaço de 13 dimensões.