

### **1) Defina computação bioinspirada**

Computação bioinspirada é uma área da inteligência artificial que desenvolve algoritmos inspirados em comportamentos e processos encontrados na natureza. Esses métodos utilizam ideias baseadas na evolução biológica, no funcionamento do cérebro humano e no comportamento coletivo de animais para resolver problemas computacionais complexos, como classificação, otimização e aprendizado. Exemplos incluem algoritmos genéticos, redes neurais artificiais e inteligência de enxames.

**2) Dos algoritmos bioinspirados apresentados em sala de aula (evolutivos, redes neurais artificiais e enxame) pesquise um algoritmo evolutivo e sua aplicação no cotidiano. Classifique o algoritmo pesquisado como evolutivo, redes neurais ou enxames e explique sua aplicação no dia a dia, com exemplos. Apresente as fontes usadas para pesquisa.**

Um exemplo de algoritmo bioinspirado é o Algoritmo Genético, classificado como um algoritmo evolutivo. Esse método é inspirado no processo de evolução natural dos seres vivos, utilizando conceitos como seleção natural, cruzamento e mutação para encontrar soluções cada vez melhores para um problema.

O funcionamento do algoritmo ocorre através de uma população de soluções candidatas. As melhores soluções são selecionadas e combinadas entre si, gerando novas soluções que passam por mutações aleatórias. Ao longo das gerações, o algoritmo tende a encontrar respostas mais eficientes para o problema analisado.

No cotidiano, algoritmos genéticos podem ser utilizados em problemas de otimização, como planejamento de rotas, logística, recomendação de produtos e escalonamento de tarefas. Um exemplo prático é o uso em aplicativos de entrega e GPS, onde o algoritmo ajuda a encontrar caminhos mais rápidos e econômicos. Também pode ser aplicado em sistemas industriais para reduzir custos e melhorar a organização da produção.

No simulador “Evolutionary Algorithm Playground”, é possível visualizar na prática o processo evolutivo do algoritmo, observando como as soluções vão melhorando ao longo das gerações através da seleção e mutação das melhores combinações.

**Fontes utilizadas:** [Algoritmo Genético na prática com Python](#)

**3) Explique os estágios da propagação das informações no perceptron multicamadas camadas de entrada, oculta ou densa e saída. Faça uma comparação do perceptron multicamadas com o perceptron simples (perceptron com um neurônio).**

No perceptron multicamadas (MLP), os dados passam inicialmente pela camada de entrada, responsável por receber as informações do problema. Em seguida, os dados são enviados para as camadas ocultas ou densas, onde ocorrem os cálculos matemáticos e a extração de padrões mais complexos através das funções de ativação. Por fim, a camada de saída produz a classificação ou previsão final da rede.

O perceptron simples possui apenas um neurônio e consegue resolver apenas problemas linearmente separáveis. Já o perceptron multicamadas possui várias camadas e múltiplos neurônios, permitindo resolver problemas muito mais complexos e não lineares através do treinamento com retropropagação.

#### **4) Explique as etapas de extração de características de uma rede neural convolucional CNN.**

A extração de características em uma CNN começa na camada de convolução, onde filtros percorrem a imagem identificando padrões como bordas, formas, brilho e texturas. Depois é aplicada uma função de ativação, normalmente ReLU, para introduzir não linearidade no modelo.

Em seguida, ocorre a camada de pooling, responsável por reduzir a dimensionalidade dos mapas de características e diminuir o custo computacional. Após isso, a operação de flatten transforma os mapas bidimensionais em um vetor unidimensional. Por fim, os dados seguem para as camadas totalmente conectadas, que realizam a classificação final da imagem.

#### **5) Elabore um projeto empregando uma rede neural convolucional anotando a estrutura de todos os hiperparâmetros necessários para o seu projeto de CNN.**

Projeto: Classificação de imagens médicas para identificar pneumonia em radiografias pulmonares.

Estrutura da CNN:

- Entrada: imagens 224x224 pixels
- Camada convolucional:
  - 32 filtros
  - kernel 3x3
  - stride 1
  - padding “same”
  - ativação ReLU
- Camada de pooling: Max Pooling 2x2
- Segunda camada convolucional:
  - 64 filtros
  - kernel 3x3
  - ativação ReLU
- Segunda camada de pooling: Max Pooling 2x2
- Flatten
- Camada densa: 128 neurônios, ativação ReLU
- Dropout: 0,5
- Camada de saída: 2 neurônios, ativação Softmax

Hiperparâmetros:

- Learning rate: 0,001
- Batch size: 32
- Epochs: 50
- Otimizador: Adam
- Função de perda: Binary Cross-Entropy

- Regularização: Dropout e Early Stopping

Esse modelo pode ser utilizado para auxiliar médicos no diagnóstico automático de pneumonia através de imagens médicas.