

Resultados - Treinamento CNN

Foi implementada uma Rede Neural Convolucional baseada na arquitetura MobileNetV2 para a classificação de cinco classes de flores: margarida (daisy), dente-de-leão (dandelion), rosas (roses), girassóis (sunflowers) e tulipas (tulips). O modelo utilizou pesos pré-treinados da ImageNet e foi treinado com uma divisão dos dados de 70% para treinamento, 15% para validação e 15% para teste.

Análise das métricas de classificação

As métricas de classificação obtidas demonstram que o modelo apresentou um bom desempenho na tarefa de classificação das flores. A acurácia indica a proporção total de classificações corretas realizadas pelo modelo. Os valores de precisão mostram a capacidade do modelo de evitar falsos positivos, enquanto os valores de revocação (recall) indicam a capacidade de identificar corretamente as amostras pertencentes a cada classe. O F1-Score, por sua vez, representa o equilíbrio entre precisão e recall.


Observou-se que os valores dessas métricas ficaram elevados para a maioria das classes, indicando que o modelo conseguiu aprender características relevantes das flores presentes nas imagens. Eventuais diferenças entre as métricas de determinadas classes podem estar relacionadas à semelhança visual entre algumas espécies de flores ou à variação de iluminação, ângulo e fundo das imagens.

	precision	recall	f1-score	support
daisy	0.86	0.93	0.89	85
dandelion	0.94	0.94	0.94	146
roses	0.83	0.93	0.88	88
sunflowers	0.95	0.90	0.92	102
tulips	0.94	0.85	0.90	136
accuracy			0.91	557
macro avg	0.90	0.91	0.91	557
weighted avg	0.91	0.91	0.91	557

Análise das curvas de acurácia e perda

As curvas de acurácia de treinamento e validação apresentaram crescimento ao longo das épocas, demonstrando que o modelo foi capaz de aprender padrões úteis para a classificação das imagens. Paralelamente, as curvas de perda (loss) apresentaram redução progressiva, indicando melhoria no processo de otimização.


A proximidade entre as curvas de treinamento e validação sugere que o modelo apresentou boa capacidade de generalização, sem sinais significativos de sobreajuste (overfitting). Caso exista uma diferença muito grande entre as curvas, isso indicaria que o modelo estaria memorizando os dados de treinamento em vez de aprender características gerais.



Análise da matriz de confusão

A matriz de confusão permite visualizar detalhadamente os acertos e erros do modelo para cada classe. Os maiores valores concentraram-se na diagonal principal da matriz, indicando que a maioria das imagens foi classificada corretamente.


Os erros observados ocorreram principalmente entre classes visualmente semelhantes. Isso é esperado em problemas de classificação de flores, pois algumas espécies apresentam formatos de pétalas, cores e texturas bastante parecidos. Apesar disso, o número de classificações incorretas permaneceu reduzido em comparação ao total de amostras avaliadas.



Análise das curvas ROC e valores AUC

As curvas ROC (Receiver Operating Characteristic) avaliam a capacidade discriminativa do modelo para cada classe. Quanto mais próxima a curva estiver do canto superior esquerdo do gráfico, melhor será a capacidade de separação entre as classes.


Os valores de AUC (Area Under the Curve) obtidos foram elevados, indicando excelente capacidade de distinção entre as diferentes categorias de flores. Valores de AUC próximos de 1 representam classificadores com alta eficiência, enquanto valores próximos de 0,5 indicariam comportamento semelhante ao acaso. Dessa forma, os resultados evidenciam que o modelo conseguiu diferenciar adequadamente as classes presentes no conjunto de dados.



Análise do gráfico de acertos e erros por classe

O gráfico de colunas demonstrou que a quantidade de acertos foi significativamente superior à quantidade de erros em todas as classes analisadas. Isso reforça os resultados observados nas métricas de classificação e na matriz de confusão.

As classes com maior quantidade de acertos indicam que suas características visuais foram mais facilmente aprendidas pelo modelo. Já as classes com maior número de erros podem apresentar maior variabilidade interna ou semelhanças com outras categorias.



Análise do tempo de treinamento e validação

O tempo total de treinamento e validação representa o custo computacional do modelo. A utilização da arquitetura MobileNetV2 mostrou-se vantajosa por combinar boa precisão com baixo custo computacional, permitindo treinamento relativamente rápido mesmo em ambientes como o Google Colab.


Além disso, o uso de transferência de aprendizado (transfer learning) reduziu significativamente o tempo necessário para o treinamento, uma vez que a rede já possuía conhecimento prévio adquirido na base ImageNet.

```
Epoch 1/10
81/81 ————— 138s 2s/step - accuracy: 0.9463 - loss: 0.1501 - val_accuracy: 0.8768 - val_loss: 0.3393
Epoch 2/10
81/81 ————— 138s 2s/step - accuracy: 0.9506 - loss: 0.1218 - val_accuracy: 0.9007 - val_loss: 0.2977
Epoch 3/10
81/81 ————— 119s 1s/step - accuracy: 0.9650 - loss: 0.1048 - val_accuracy: 0.8860 - val_loss: 0.3711
Epoch 4/10
81/81 ————— 142s 1s/step - accuracy: 0.9704 - loss: 0.0844 - val_accuracy: 0.8915 - val_loss: 0.3497
Epoch 5/10
81/81 ————— 120s 1s/step - accuracy: 0.9735 - loss: 0.0798 - val_accuracy: 0.8971 - val_loss: 0.3783
Epoch 6/10
81/81 ————— 120s 1s/step - accuracy: 0.9708 - loss: 0.0813 - val_accuracy: 0.8952 - val_loss: 0.3494
Epoch 7/10
81/81 ————— 119s 1s/step - accuracy: 0.9782 - loss: 0.0654 - val_accuracy: 0.8787 - val_loss: 0.3824
Epoch 8/10
81/81 ————— 142s 1s/step - accuracy: 0.9782 - loss: 0.0630 - val_accuracy: 0.8860 - val_loss: 0.3745
Epoch 9/10
81/81 ————— 140s 2s/step - accuracy: 0.9782 - loss: 0.0602 - val_accuracy: 0.8971 - val_loss: 0.4235
Epoch 10/10
81/81 ————— 141s 2s/step - accuracy: 0.9856 - loss: 0.0437 - val_accuracy: 0.9026 - val_loss: 0.3006
Tempo de treinamento: 22.04 minutos
```


Análise da explicabilidade utilizando Grad-CAM

A técnica Grad-CAM foi utilizada para visualizar as regiões das imagens consideradas mais importantes para a tomada de decisão do modelo. Os mapas de ativação mostraram que a rede concentrou sua atenção principalmente sobre as flores, destacando pétalas, centro floral e outras estruturas características de cada espécie.


Esse comportamento indica que o modelo aprendeu características relevantes do objeto de interesse, em vez de focar predominantemente no fundo da imagem. Portanto, os resultados do Grad-CAM fornecem evidências adicionais de que o processo de classificação está sendo realizado com base em atributos visuais adequados das flores.



daisy



dandelion



Conclusão

Os resultados obtidos demonstram que a MobileNetV2 apresentou desempenho satisfatório na classificação das cinco espécies de flores. As métricas de classificação, os elevados valores de AUC, a predominância de acertos na matriz de confusão e no gráfico comparativo, além dos mapas de ativação gerados pelo Grad-CAM, indicam que o modelo foi capaz de aprender representações relevantes das imagens e realizar classificações confiáveis com custo computacional reduzido.