

Análise do Mundo Wumpus com Reforço

RESULTADO DO TREINAMENTO

Episódios: 5000
 Vitórias: 4964
 Taxa de sucesso: 99.28%
 Recompensa média: 96.28

POLÍTICA APRENDIDA

→	→	O	P
↑	↑	W	↑
↑	P	↑	↑
P	↑	↑	↑


MAPA FINAL

[S]	[*]	[O]	[P]
[]	[]	[W]	[]
[]	[P]	[]	[]
[P]	[]	[]	[]

MELHOR CAMINHO ENCONTRADO:

(0, 0) → (0, 1) → (0, 2)

STATUS: OURO ENCONTRADO
 Quantidade de passos: 2



O agente foi treinado utilizando o algoritmo Q-Learning durante 5000 episódios no ambiente do Mundo de Wumpus. O objetivo era aprender uma política capaz de conduzir o agente até a posição do ouro, evitando os estados perigosos representados pelos poços e pelo Wumpus.

Ao final do treinamento, o agente alcançou uma taxa de sucesso de 99,28%, obtendo 4964 vitórias em 5000 episódios. Esse resultado indica que a tabela Q convergiu para uma política eficiente, permitindo que o agente identificasse consistentemente o melhor caminho para atingir o objetivo.

A recompensa média obtida foi de 96,28 pontos. Como o ouro fornece uma recompensa positiva elevada (+100) e cada movimento gera uma pequena penalidade (-1), esse valor demonstra que o agente aprendeu não apenas a encontrar o ouro, mas também a fazê-lo utilizando o menor número possível de movimentos.

A política aprendida mostra que, a partir da posição inicial (0,0), o agente escolhe mover-se para a direita até alcançar a posição do ouro (0,2). O caminho encontrado foi: (0,0) → (0,1) → (0,2)

Esse trajeto possui apenas dois movimentos, representando o caminho ótimo para alcançar o objetivo. Além disso, o agente evita corretamente as células perigosas que contêm poços e o Wumpus, demonstrando que as penalidades atribuídas a esses estados foram suficientes para influenciar o aprendizado.

O mapa final evidencia que o caminho aprendido passa apenas por estados seguros, sem explorar regiões de risco desnecessariamente. Dessa forma, pode-se concluir que o algoritmo Q-Learning foi capaz de aprender uma política ótima para o ambiente proposto, maximizando a recompensa acumulada e minimizando os riscos e custos de movimentação.

Os resultados obtidos comprovam a eficiência do aprendizado por reforço na resolução do problema do Mundo de Wumpus, permitindo que o agente desenvolva um comportamento inteligente a partir da interação com o ambiente, sem conhecimento prévio sobre a localização dos perigos ou do objetivo.

O gráfico apresenta a recompensa obtida pelo agente em cada episódio de treinamento. Observa-se que a maioria dos episódios termina com recompensas próximas de 100, indicando que o agente conseguiu alcançar o ouro com sucesso. As quedas bruscas para valores negativos

representam episódios em que o agente caiu em um poço ou encontrou o Wumpus, recebendo penalidades elevadas. Como essas quedas se tornam pouco frequentes ao longo do treinamento, conclui-se que o agente aprendeu a evitar estados perigosos e a seguir a melhor estratégia para maximizar sua recompensa. O comportamento do gráfico demonstra a convergência do algoritmo Q-Learning para uma política eficiente.