

1) kNN (k = 1)

Sentença a classificar: "I always like foreign films", sem stop words: like foreign films

Dos textos de treinamento:

1. just plain boring (-)
2. entirely predictable lacks energy (-)
3. no surprises very few laughs (-)
4. very powerful (+)
5. most fun film summer (+)

Vocabulário: {just, plain, boring, entirely, predictable, lacks, energy, no, surprises, very, few, laughs, powerful, most, fun, film, summer, like, foreign, films}

A frase de teste possui: Teste = [like, foreign, films]

I) Distância Euclidiana:

Representação Bag of Words (0 ou 1).

Documento 5 (+): "The most fun film of the summer"

Vetor contém apenas film em comum com a frase de teste.

Interseção = 1 palavra. Teste possui 3 palavras. Documento possui 3 palavras.

Diferenças:

- like $\neq$ 0
- foreign $\neq$ 0
- films $\neq$ 0
- most $\neq$ 0
- fun $\neq$ 0
- summer $\neq$ 0
- film compartilhada

Distância: $d = \sqrt{6}$

Demais documentos: Não compartilham nenhuma palavra com a sentença.

Cada documento tem entre 2 e 5 palavras, resultando em distâncias maiores que $\sqrt{6}$

Logo o vizinho mais próximo é: "The most fun film of the summer" (+)

Classificação Euclidiana: Classe Positiva (+)**II) Similaridade do Cosseno**

Teste = (like, foreign, films)

Norma: $||T|| = \sqrt{3}$

Documento 5 (+): D = (most, fun, film, summer)

Considerando "film" $\approx$ "films" (stemming simples):

Produto escalar: $T \cdot D = 1$ Norma do documento: $||D|| = \sqrt{4} = 2$

Similaridade: $\cos(T, D) = \frac{1}{\sqrt{3.2}} \Rightarrow \cos(T, D) = 0,289$

Outros documentos: Não possuem palavras em comum. $\cos = 0$

Portanto o vizinho mais próximo continua sendo o documento positivo.

Classificação Cosseno: Classe Positiva (+)

2) Naive Bayes

Frase: "eu gosto deste lugar", sem stop words: gosto lugar

Probabilidades a priori

Total de documentos = 5

Negativos = 2

Positivos = 3

- $P(-) = \frac{2}{5} = 0,4$

- $P(+) = \frac{3}{5} = 0,6$

Contagem de palavras

- Classe Negativa:

Documentos:

- eu não gosto deste restaurante
- estou cansado dessas coisas

Palavras: eu, não, gosto, deste, restaurante, estou, cansado, dessas, coisas Total = 9

- Classe Positiva:

Documentos:

- eu me sinto bem com essas cervejas
- eu amo esse sanduíche
- este é um lugar incrível

Palavras: eu, me, sinto, bem, com, essas, cervejas, eu, amo, esse, sanduíche, este, lugar, incrível

Total = 14

Laplace Smoothing

Vocabulário total: {eu, não, gosto, deste, restaurante, estou, cansado, dessas, coisas, me, sinto, bem, com, essas, cervejas, amo, esse, sanduíche, este, lugar, incrível} Total: $|V| = \sqrt{21}$

- Classe Negativa:

Palavra "gosto": $P(\text{gosto} | -) = \frac{1+1}{9+21} = \frac{2}{30}$

Palavra "lugar": $P(\text{lugar} | -) = \frac{0+1}{9+21} = \frac{1}{30}$

Probabilidade: $P(-) \times P(\text{gosto} | -) \times P(\text{lugar} | -) = 0,4 \times \frac{2}{30} \times \frac{1}{30} = 0,00089$

- Classe Positiva:

$$\text{Palavra "gosto"} \quad P(\text{gosto} | +) = \frac{0+1}{14+21} = \frac{1}{35}$$

$$\text{Palavra "lugar"}: P(\text{lugar} | +) = \frac{1+1}{14+21} = \frac{2}{35}$$

$$\text{Probabilidade: } P(+) \times P(\text{gosto} | +) \times P(\text{lugar} | +) = 0,6 \times \frac{1}{35} \times \frac{2}{35} = 0,00098$$

Comparação: $0,00098 > 0,00089$ Logo: **Classificação Positivo (+)**

3) Diferença entre as representações vetoriais

Bag of Words (BoW): representa um texto pela frequência das palavras, ignorando a ordem em que aparecem.

N-gram: considera sequências de palavras consecutivas (bigramas, trigramas etc.), preservando parcialmente a ordem das palavras.

Word2Vec: representa cada palavra por um vetor denso aprendido a partir do contexto. Palavras com significados semelhantes ficam próximas no espaço vetorial.

Redes Recorrentes (RNN/LSTM/GRU): processam as palavras sequencialmente, mantendo uma memória do contexto anterior para representar a frase.

Transformers: utilizam mecanismos de atenção (self-attention) para capturar relações entre todas as palavras simultaneamente, permitindo modelar dependências longas e gerar representações contextualizadas mais eficientes que as RNNs.